Redes de Samples Musicais: Entrega Parcial F1

MC859 — Projeto em Teoria da Computação — UNICAMP 2026/S1

Prof. Dr. Ruben Interian | Matheus Henrique de S. Silva — RA 239995

27 de abril de 2026

1. Introdução e Repositório

A entrega parcial F1 deste projeto disponibiliza quatro instâncias de grafo direcionado representando relações derivativas — *sample*, *remix*, *edit*, *DJ-mix* e *mash-up* — entre gravações musicais reais. Diferentemente da proposta original — que previa coleta via *scraping* do WhoSampled.com — este F1 utiliza o dump público do MusicBrainz (núcleo, versão `20260425-002540`, licença CC0). A motivação do pivô é discutida no Apêndice A.

Repositório público (instâncias e código): `github.com/MatheusHenriqueSS/MC859A_2026S1`

Conteúdo do repositório:

- `mb_sample_graph.graphml` — grafo nível-faixa
- `mb_artist_graph.graphml` — grafo nível-artista
- `mb_decade_graph.graphml` — grafo nível-década
- `mb_country_graph.graphml` — grafo nível-país
- `src/extract_tsvs.py`, `src/build_mb_graph.py` — código reprodutível
- `graph_output/*_stats.txt` e `*.png` — estatísticas e visualizações

2. Coleta dos Dados

A fonte de dados é o *core dump* público do MusicBrainz (`mbdump.tar.bz2`, 6,7 GB comprimidos, ∼50 GB descomprimidos). O dump contém o estado completo do banco em formato `COPY` do PostgreSQL, com uma tabela por arquivo TSV. Para evitar a descompressão total, foi implementado um extrator seletivo (`extract_tsvs.py`) que percorre o tarball uma única vez e grava apenas as 12 tabelas necessárias para o grafo: `artist`, `artist_credit`, `artist_credit_name`, `recording`, `track`, `link`, `link_type`, `l_recording_recording`, `area`, `medium`, `release_country`, `release_unknown_country`.

Após extração, os TSVs totalizam 17 GB em disco. A tabela mais relevante para a topologia do grafo é `l_recording_recording`, que contém todas as relações entre gravações curadas pelos usuários do MusicBrainz (338.681 linhas no dump utilizado).

3. Construção das Instâncias de Grafo

A pipeline (`build_mb_graph.py`) carrega os 12 TSVs no DuckDB, realiza os *joins* relevantes e produz quatro instâncias derivadas do mesmo conjunto-base de arestas. Os passos principais são:

1. Filtrar `l_recording_recording` pelos cinco tipos de relação derivativa entre gravações disponíveis no MusicBrainz: `samples material` (23.776 arestas), `remix` (130.707), `edit` (32.403), `DJ-mix` (22.487) e `mashes up` (21.676). Total: 231.049 arestas.

2. Computar uma proxy de popularidade definida como número de *tracks* (lançamentos) em que cada *recording* aparece; descartar arestas em que algum dos extremos não tenha pelo menos uma aparição em algum lançamento (limiar 1, escolhido pelo *picker* automático). Resultado: 223.018 arestas.
3. Enriquecer cada aresta com: nome da gravação, artista primário, país do artista (via `artist.area` restrito a `area.type=1`), e ano da primeira publicação (via `track` → `medium` → `release_country/unknown`).
4. Construir o grafo nível-faixa em NetworkX, deduplicando múltiplas relações entre o mesmo par (u, v) em uma aresta única com peso e lista de tipos.
5. Agregar para grafos derivados: nível-artista (colapsando faixas do mesmo artista), nível-década (década da primeira publicação) e nível-país (país do artista).

A orientação das arestas segue a convenção *derivada* → *original*: aresta $A \to B$ significa que A sampleia, remixa ou cobre B. Assim, *in-degree* mede quanto uma gravação foi usada como fonte; *out-degree* mede quanto ela usou outras fontes.

4. Análise Inicial

4.1 Visão Comparativa

A Tabela 1 sumariza as quatro instâncias entregues. Todas são grafos direcionados.

Instância	Vért.	Arestas	Dens.	$\bar{d}$	#SCC	maior SCC	#WCC	maior WCC
Faixa	321.738	222.696	$2{,}2 \cdot 10^{-6}$	0,69	321.718	3	106.283	36.297
Artista	47.286	41.014	$1{,}8 \cdot 10^{-5}$	0,87	46.789	404	25.014	19.348
Década	13	88	$5{,}6 \cdot 10^{-1}$	6,77	4	10	1	13
País	159	1.003	$4{,}0 \cdot 10^{-2}$	6,31	88	72	36	124

Tabela 1: Dimensões, densidade, grau médio (*in*=*out* em direcionado), e estrutura de componentes das quatro instâncias. #SCC: número de componentes fortemente conexas; #WCC: número de componentes fracamente conexas. As metas mínimas da proposta (≥50.000 vértices, ≥150.000 arestas) são atendidas pela instância nível-faixa.

Distribuição por tipo de relação (grafo nível-faixa, após deduplicação): `remix` 128.560 (57,7%), `edit` 31.728, `sample` 22.706, `dj_mix` 21.222, `mashup` 18.668. *Remix* é, portanto, o mecanismo dominante de derivação curado no MusicBrainz, com *sample* representando ∼10% das arestas.

4.2 Distribuição de Grau e Componentes

A Figura 1 mostra a distribuição de grau do grafo nível-faixa (escala simétrica-log). A cauda longa é compatível com uma rede livre de escala: poucos hubs com dezenas a centenas de arestas, enquanto a maioria das faixas tem grau 1. Entre os 20 mais sampleados/remixados destacam-se PSY — *Gangnam Style* (217), Lyn Collins — *Think (About It)* (132), :wumpscut: — *Wreath of Barbs* (131), Quad City DJ's — *Space Jam* (86), Smash Mouth — *All Star* (70), The Honey Drippers — *Impeach the President* (58), The Winstons — *Amen, Brother* (53) e Daft Punk — *Harder, Better, Faster, Stronger* (47). A presença simultânea de *breaks* clássicos do hip-hop e de sucessos pop modernos confirma que o grafo cobre tanto sampling canônico quanto remixagem contemporânea.

Componentes (grafo direcionado). O grafo nível-faixa apresenta 321.718 componentes fortemente conexas (SCC), todas com no máximo 3 nós — ou seja, é essencialmente um DAG, refletindo o caráter cronológico das relações de derivação. Em termos de componentes *fracamente* conexas (WCC), há 106.283 componentes com a maior abrangendo 36.297 nós (11,3% do total). A componente gigante é *menor em proporção* do que no scrape do WhoSampled (∼80%) precisamente porque as relações de *remix* no MusicBrainz tendem a formar pequenas estrelas em torno de uma faixa-fonte e raramente conectam-se entre si. A Figura 2 traz a distribuição de tamanhos.

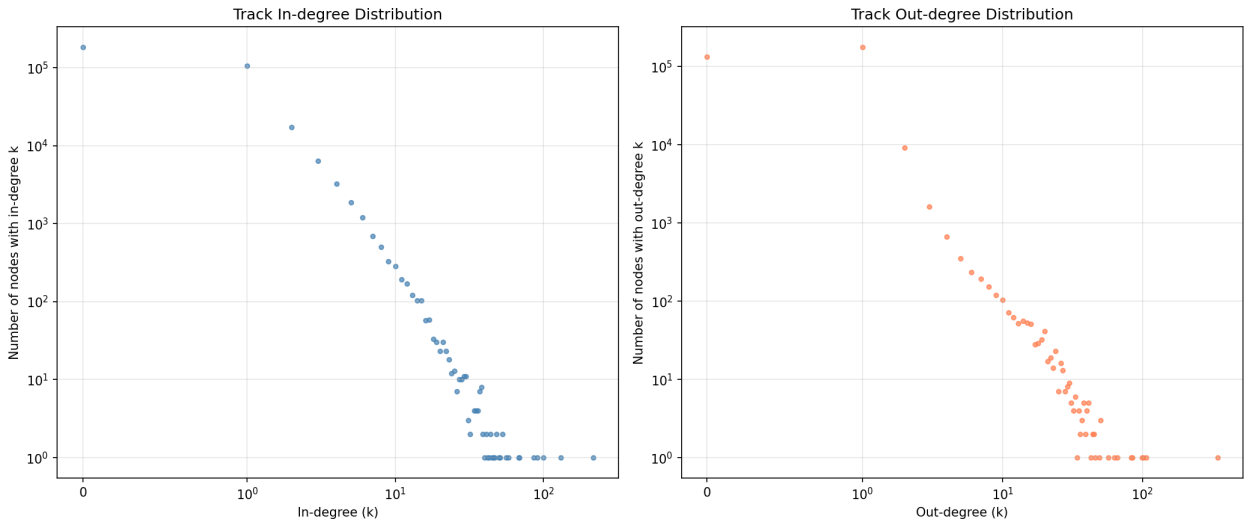

Figura 1: Distribuição de grau (*in*/*out*, escala simétrica-log) do grafo nível-faixa.

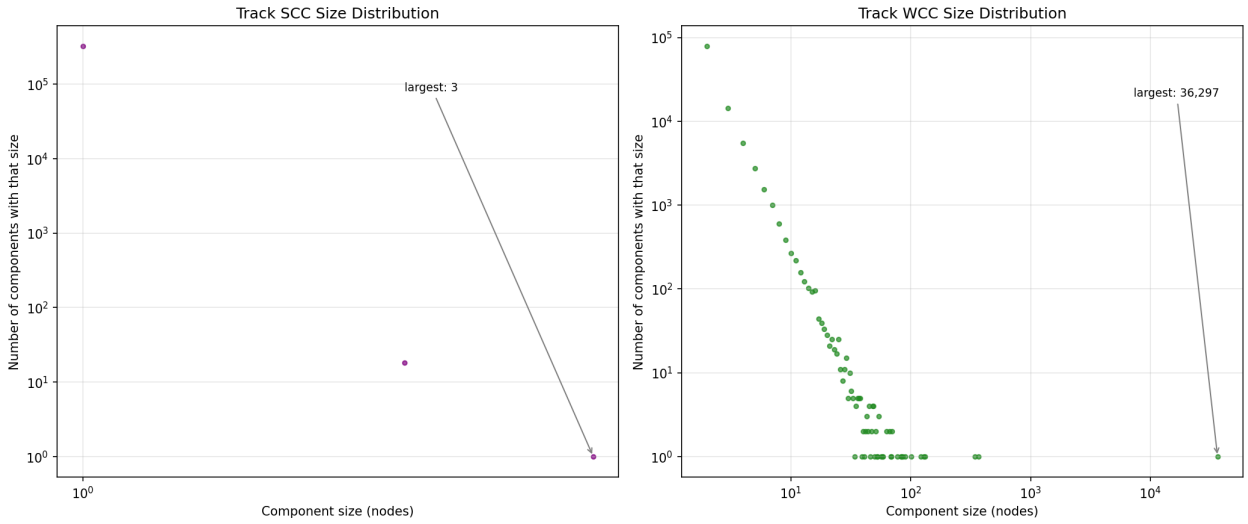

Figura 2: Distribuição de tamanhos de componentes (SCC e WCC) — grafo nível-faixa.

A agregação para nível-artista produz uma rede menos fragmentada: maior WCC = 19.348 nós (40,9%), maior SCC = 404 nós, evidenciando um *cluster* considerável de artistas que mutuamente se remixam/sampleiam. As Tabelas 2 e 3 resumem os achados nas instâncias agregadas.

5. Discussão

Os achados são consistentes com a literatura de *sampling* musical e ainda revelam padrões além do escopo de *sample* estrito. Os hubs do grafo nível-faixa misturam (i) *breaks* canônicos (*Funky Drummer*, *Amen Brother*, *Impeach the President*, *Think (About It)*) e (ii) sucessos pop intensamente remixados (*Gangnam Style*, *Space Jam*, *All Star*, *Call Me Maybe*). A assimetria temporal subsiste — anos 60–70 quase nunca produzem arestas de saída, mas recebem milhares — mas a inclusão de *remix* e *edit* desloca o pico de in-strength para os anos 2010, refletindo a era de produção musical digital (EDM, mash-ups, *bootlegs*). Geograficamente, EUA e Reino Unido concentram quase 80% do fluxo total; Brasil ocupa a 20ª posição em ambas as direções, com fluxo aproximadamente balanceado.

A escala obtida (222.696 arestas, 321.738 vértices) supera a meta original da proposta ($\geq$150.000 arestas, $\geq$50.000 vértices) e é comparável ao *scrape* preliminar de WhoSampled ($\sim$167.000 arestas, $\sim$153.000 vértices)

Década	In	Out
2010s	79.038	87.404
2000s	46.061	42.287
2020s	40.178	62.130
1990s	27.654	20.753
1980s	13.077	4.660
1970s	9.021	1.060
1960s	3.521	779
1950s	479	102

Tabela 2: Top-8 décadas por força ponderada de in-/out-degree. A inclusão de relações de *remix*, *edit* e *DJ-mix* torna a década de 2010 dominante em ambos os sentidos, refletindo a era de produção musical digital.

País	In	Out
EUA	50.673	46.690
Reino Unido	28.600	29.032
Japão	14.700	14.062
Alemanha	10.803	10.902
França	5.788	6.550
Holanda	4.810	5.354
Canadá	4.576	5.954
Itália	4.203	4.070
Brasil	873	914

Tabela 3: Top-8 países e Brasil por força ponderada. Brasil aparece em #20 em ambas as direções, com fluxo aproximadamente balanceado (sampleia ≈ é sampleado).

que havia sido descontinuado. A próxima fase (F2) prevê: enriquecimento via *tags* de gênero do próprio MusicBrainz para uma instância nível-gênero; expansão para *cover* a nível de *work*; e cruzamento com a Spotify API para popularidade contemporânea e detecção de fluxo de influência cruzando gerações.

Apêndice A — Pivô WhoSampled → MusicBrainz

A proposta original previa *scraping* do WhoSampled.com e citava Figueiredo et al. (*Surprising Patterns in Musical Influence Networks*, arXiv:2410.15996, 2024) como referência de escala (166.016 artistas, 603.487 arestas a partir de 1.250.246 músicas).

Durante o F1 verificou-se que: (i) os termos de uso do WhoSampled restringem extração massiva por terceiros; (ii) a metodologia da referência citada declara explicitamente que "*the WhoSampled dataset was provided after an agreement with WhoSampled.com*" — ou seja, os 166.016 nós foram obtidos por **acordo institucional direto**, não por *scraping*; (iii) o conjunto não é redistribuído publicamente. Assim, a meta de escala original é, na prática, **inalcançável por meios reprodutíveis** no escopo de um projeto de graduação.

A pivotagem para o MusicBrainz (CC0, dump público versionado) sacrifica escala mas garante: (1) reprodutibilidade byte-a-byte por qualquer revisor a partir do dump publicado; (2) ausência de contingências de *scraping* (rate-limiting, mudanças de DOM, banimento de IP); (3) licenciamento permissivo. Para um projeto acadêmico cujo critério é a análise estrutural do grafo — não o seu volume bruto — esta troca é consistente com os princípios de ciência aberta e transparência de método.