

Redes de Samples Musicais: Entrega Final F2

Extração de Conhecimento e Detecção de Padrões em Grafos de Derivação Musical

MC859 — Projeto em Teoria da Computação — UNICAMP 2026/S1

Prof. Dr. Ruben Interian | Matheus Henrique de S. Silva — RA 239995

22 de junho de 2026

1 Introdução e Repositório

A entrega F1 disponibilizou quatro instâncias de grafo direcionado representando relações derivativas (*sample*, *remix*, *edit*, *DJ-mix*, *mash-up*) entre gravações musicais reais, extraídas do dump público do MusicBrainz (CC0, versão 20260425-002540). A entrega final F2, descrita neste relatório, executa **algoritmos de grafo sobre essas instâncias para extrair conhecimento e detectar padrões**, organizando os achados em cinco pilares analíticos (influência, comunidades, estrutura, tempo e geografia), uma camada adicional de gênero, e um estudo de caso aprofundado sobre o **Brasil**.

Repositório público (instâncias, código e artefatos): github.com/MatheusHenriqueSS/MC859A_2026S1

Novos artefatos da F2 no repositório:

- `src/analyze_*.py` — pipeline reproduzível de análise (cinco pilares + gênero + Brasil); `src/graphs.py` — registro de instâncias.
- `graph_output/mb_sample_graph_v2.graphml.gz` — grafo nível-faixa enriquecido com *ano* e *país* por nó; `mb_genre_graph.graphml.gz` — instância nível-gênero.
- `analysis_output/` — rankings (CSV+TXT), sumários JSON, figuras e o subgrafo do Brasil (`br_subgraph.graphml.gz`).

Todas as instâncias são armazenadas como GraphML *gzipado* (`*.graphml.gz`), lido nativamente pelo NetworkX e $\sim 8\times$ menor em disco. A pilha de software é Python 3.12 com `networkx 3.6`, `python-louvain`, `leidenalg/igraph`, `powerlaw`, `scipy` e `duckdb`; toda a análise CC0 é reproduzível a partir do dump, sem segredos.

2 Dados e Instâncias

2.1 Coleta e construção (recapitulação)

A fonte é o *core dump* do MusicBrainz (6,7 GB comprimidos). Um extrator seletivo (`extract_tsvs.py`) percorre o tarball uma vez e grava 12 tabelas em TSV; a pipeline (`build_mb_graph.py`) carrega-as no DuckDB, filtra a tabela `l_recording_recording` pelos cinco tipos de relação derivativa e constrói o grafo nível-faixa, deduplicando múltiplas relações entre o mesmo par (u, v) em uma aresta com *peso* e *lista de tipos*. A convenção de orientação é **derivada** $\rightarrow$ **original**: $A \rightarrow B$ significa que *A* sampleia, remixa ou cobre *B*. Logo, *in-strength* mede o quanto uma gravação foi **usada como fonte**; *out-strength*, o quanto ela **deriva de outras**.

2.2 Enriquecimentos da F2

Duas extensões foram necessárias para os pilares temporal, geográfico e de gênero:

- **Ano + país por nó** (`build_track_v2.py`): re-emissão do grafo nível-faixa com *ano* da primeira publicação (cobertura 99,2%) e *país* do artista (75%) em cada nó.

- **Camada de gênero** (`build_genre_graph.py`): as *tags* de gênero residem no *dump derivado* do MusicBrainz (`mbdump-derived`), não no núcleo. Um gênero por gravação é resolvido por *fallback* de três níveis (gravação $\rightarrow$ álbum/*release-group* $\rightarrow$ artista), atingindo **83,1% de cobertura**; a agregação produz a instância nível-gênero (888 gêneros).

A Tabela 1 resume as instâncias analisadas. A nível-faixa é essencialmente um DAG (maior SCC = 3 nós), refletindo o caráter cronológico das derivações; a fragmentação alta (maior WCC com 11,3% dos nós) decorre de relações de *remix* formarem pequenas estrelas isoladas.

Instância	Vértices	Arestas	Atributos de nó	Observação estrutural
Faixa (v2)	321.738	222.696	título, artista, ano, país, pop.	quase-DAG; maior WCC 36.297 (11,3%)
Artista	47.286	41.014	artista, n ^o de faixas	maior WCC 19.348 (40,9%); SCC 404
Gênero	888	10.944	gênero	densa; homofilia 8,13×
Década	13	88	década	densa; 2010s dominante
País	159	1.003	n ^o de extremos	EUA/RU $\approx$ 80% do fluxo

Tabela 1: Instâncias de grafo direcionado analisadas na F2. A nível-faixa atende às metas mínimas da proposta (≥ 50.000 vértices, ≥ 150.000 arestas).

3 Metodologia e Algoritmos

Os cinco pilares aplicam algoritmos clássicos de grafo, sempre respeitando a orientação derivada $\rightarrow$ original. Decisões metodológicas transversais: (i) **remoção de nós-agregadores** (`[unknown]`, *Various Artists* etc.) antes de qualquer centralidade/comunidade a nível de artista, pois são super-nós que distorcem os resultados; (ii) **HITS restrito à maior WCC**, onde é coerente (é degenerado no grafo desconexo completo); (iii) **PageRank no grafo original** mede influência de fonte (o *rank* acumula em fontes de alto in-degree), enquanto no grafo *revertido* mede alcance curatorial do sampler. Os Algoritmos 1–4 sintetizam os procedimentos centrais.

Algoritmo 1. *Ranking de influência e papéis (nível-faixa e nível-artista)*

Entrada: grafo direcionado G ($A \rightarrow B$: A deriva de B), pesos nas arestas. **Saída:** top- k por papel.

1. $G_{\text{rev}} \leftarrow \text{REVERSE}(G)$
 2. $pr_{\text{fonte}} \leftarrow \text{PAGERANK}(G)$ $\triangleright$ acumula em fontes (alto in-degree)
 3. $pr_{\text{curad}} \leftarrow \text{PAGERANK}(G_{\text{rev}})$ $\triangleright$ alcance curatorial do sampler
 4. $W \leftarrow$ maior componente fracamente conexa de G
 5. $(\text{auth}, \text{hub}) \leftarrow \text{HITS}(W)$ $\triangleright$ autoridade = fonte; hub = sampler
 6. **para cada** $v \in G$: $\text{papel}(v) \leftarrow$ quadrante de $(\text{in_str}(v), \text{out_str}(v))$
 7. **retorne** top- k de pr_{fonte} , pr_{curad} , auth , hub e betweenness em W
-

Algoritmo 2. *Detecção de comunidades e caracterização de cenas (nível-artista)*

Entrada: grafo de artistas A . **Saída:** partição P e modularidade.

1. $A \leftarrow \text{REMOVEPLACEHOLDERS}(A)$ $\triangleright$ remove super-nós agregadores
 2. $W \leftarrow$ maior WCC de A ; $U \leftarrow$ versão não-direcionada ponderada de W
 3. $P_{\text{lv}} \leftarrow \text{LOUVAIN}(U)$; $P_{\text{ld}} \leftarrow \text{LEIDEN}(U)$
 4. **para cada** comunidade $c \in P$: caracterizar por (tipo dominante, décadas, países, top membros)
 5. **retorne** P , modularidade(P)
-

Algoritmo 3. *Homofilia por atributo via modelo nulo de independência (país / gênero)*

Entrada: grafo agregado X com *self-loops*; atributo categórico por nó. **Saída:** razão de homofilia.

1. $W \leftarrow \sum_e w(e)$; $W_{\text{self}} \leftarrow \sum_{e: u=v} w(e)$
 2. $\text{obs} \leftarrow W_{\text{self}}/W$ $\triangleright$ fração observada de arestas intra-categoria
 3. $\text{esp} \leftarrow \sum_c (\text{in_str}(c)/W) \cdot (\text{out_str}(c)/W)$ $\triangleright$ nulo de independência
 4. **retorne** obs/esp
-

Algoritmo 4. *Fluxo de influência temporal (nível-faixa com ano)*

Entrada: grafo de faixas G com ano por nó. **Saída:** distribuição de lag, *evergreen*, cadeia máxima.

1. **para cada** aresta $u \rightarrow v$ com anos: lag $\leftarrow$ ano(u) – ano(v); classificar consistente(> 0)/mesmo-ano(0)/violação(< 0)
 2. *evergreen* $\leftarrow$ {fontes com derivadas em ≥ 5 décadas}
 3. cadeia $\leftarrow$ maior caminho no sub-DAG de derivação
 4. **retorne** distribuição de lag, *evergreen*, cadeia máxima
-

O ajuste da distribuição de grau (pilar estrutural) usa a biblioteca **powerlaw**: estima-se α e compara-se *power-law* contra *lognormal* e *exponencial* via razão de verossimilhança R (com p -valor). Assortatividade de grau/atributo, reciprocidade e transitividade são calculadas pelo NetworkX.

4 Resultados

4.1 Influência e papéis

O PageRank de *fonte* no grafo nível-faixa eleva ao topo gravações intensamente reutilizadas: *wumpscut*: — *Wreath of Barbs*, *PSY* — *Gangnam Style*, *Arca* — *Riquiquí*, *Lyn Collins* — *Think (About It)*, *The Honey Drippers* — *Impeach the President* e *Public Enemy* — *Bring the Noise*. No grafo revertido, o topo é ocupado por *mega-mixes* e *sets* de DJ (Armin van Buuren — *ASOT 1000*, deadmau5 — *mau5trap radio*), que agregam centenas de fontes. A nível de artista, os papéis separam-se nitidamente (Tabela 2): **HITS** identifica como *autoridades* as estrelas pop mais “mashadas” (Katy Perry, Lady Gaga, Britney Spears) e como *hubs* os produtores de *mashup* (SmadaLeinad, DJ Schmolli, Triple-Q); a **betweenness** destaca artistas-ponte entre cenas (Beyoncé, The Weeknd, Koji Kondo, JAY-Z). A Figura 1 mostra o quadrante de papéis in-/out-strength.

PageRank-fonte	Curatorial (rev.)	Autoridade (HITS)	Hub (HITS)	Betweenness
Daniel Ingram	Triple-Q	Katy Perry	SmadaLeinad	Beyoncé
Daft Punk	DJ Schmolli	Kesha	DJ Schmolli	The Weeknd
James Brown	Masayuki Suzuki	Lady Gaga	Triple-Q	Koji Kondo
Lyn Collins	goreshit	Britney Spears	Robin Skouteris	Psynwav
Kraftwerk	1086 Productions	Rihanna	DJ Earworm	JAY-Z

Tabela 2: Top-5 artistas por papel. Fontes fundacionais (funk/eletrônico), sampleadores curatoriais (DJs/mashups), autoridades (pop) e pontes coincidem com a intuição musical: cada métrica isola um papel distinto na rede.

4.2 Comunidades e cenas musicais

Sobre a maior WCC de artistas (19.348 nós, reduzidos a 18.464 após remover os super-nós agregadores — Alg. 2), Louvain encontra 92 comunidades com modularidade **0,6464** (Leiden: 100 comunidades, 0,6067) — uma estrutura de comunidades forte. As maiores comunidades mapeiam-se de forma quase exata a **cena** = **gênero** + **época** + **país** (Tabela 3), validando que a topologia de sampling captura agrupamentos culturalmente significativos sem qualquer rótulo de gênero como entrada.

4.3 Caracterização estrutural

A distribuição de in-degree é de cauda pesada, mas o ajuste rigoroso **rejeita a hipótese “livre de escala”**: embora $\alpha \approx 2,61$ (faixa) e 2,24 (artista), a *lognormal* vence a *power-law* de forma decisiva ($R = -177,96$, $p \approx 0$ no nível-faixa). A rede é quase acíclica: reciprocidade $\approx 1,6 \times 10^{-4}$, assortatividade de grau $\approx -0,02$ (neutra), transitividade $\approx 0,003$. Há forte tendência **intra-país** (fração de arestas ligando o mesmo país $\approx 0,88$) e **assortatividade de ano** (0,67): faixas conectam-se a outras do mesmo país e de épocas próximas. A comparação por tipo de relação (Tabela 4) é reveladora: *sample* forma cadeias conectadas e relativamente




Figura 1: Quadrante de papéis (in-strength = usado como fonte vs. out-strength = sampleia outros) na maior WCC de artistas.

coesas (maior cadeia 4, WCC gigante 22,6%) e *mashup* é uma única teia rasa (WCC gigante **60,5%**, cadeia 2), ao passo que *remix*, embora majoritariamente estrelas locais isoladas (WCC gigante 0,2%), abriga a *maior* linhagem individual de todas (cadeia de **9** saltos). A Figura 2 mostra a distribuição de grau.

Decomposição em k-cores (backbone denso). Para isolar o núcleo *mutuamente* mais conectado — o que nenhuma das centralidades anteriores captura —, computamos a decomposição em k-cores do grafo de artistas (projeção não-dirigida sem self-loops, super-nós removidos): peneiram-se iterativamente os nós de grau $< k$, e o maior k com subgrafo não-vazio é a *degeneração*. Dos 23.582 artistas do backbone interconectado, **70,9% ocupam core ≤ 1** (folhas e estrelas) e apenas **136 (0,58%)** atingem o core máximo (degeneração **14**) — uma assinatura *core/periferia* (Figura 3) que quantifica o caráter *hub-and-spoke* já sugerido pelo ajuste lognormal; a maior componente conexa, 18.464, reproduz exatamente o valor obtido na detecção de comunidades. O 14-core mistura as estrelas pop/rock mais remixadas (Daft Punk, The Beatles, Lady Gaga, Michael Jackson) com o cânone de *sampling* do hip-hop (JAY-Z, Beastie Boys, James Brown, Ye) e os produtores de *mashup/bootleg* que os entrelaçam (DJ Schmolti, Girl Talk, Neil Cicierega). Sobretudo, esses 136 artistas **atravessam 13 comunidades de Louvain** — *mashup*-pop (51), rap moderno (20), *breaks* de funk (16), *mashup* rock (16), *French touch* (8) — revelando que o subgrafo mais denso não é uma cena isolada, mas o *tecido conectivo* entre elas. No nível de faixa a degeneração cai para 8 e o 8-core (16 nós) é um *artefato de catálogo* (uma demo multilíngue do *Bose Lifestyle music system* mais compilações orquestrais), reforçando que a unidade de análise musicalmente interpretável é o artista.

4.4 Fluxo de influência temporal

Em 218.857 arestas com ambos os anos conhecidos, apenas **3,3% violam a cronologia** (54,8% têm *lag* positivo e 41,9% ocorrem no mesmo ano); o *lag* mediano é 1 ano (médio 5,08), mas o *lag* mediano específico de *sample* sobe para **14 anos** — *sampling* reativa material substancialmente mais antigo que o *remix*

Tam.	Tipo dom.	País dom.	Membros principais $\Rightarrow$ cena
2211	sample	EUA	James Brown, Public Enemy, Isaac Hayes, Notorious B.I.G. $\Rightarrow$ <i>breaks</i> de funk no hip-hop
1729	mashup	RU/EUA	The Beatles, Michael Jackson, Queen, Metallica $\Rightarrow$ <i>mashup</i> rock clássico
1310	mashup	EUA	Lady Gaga, Katy Perry, Britney, Madonna, Taylor Swift $\Rightarrow$ <i>mashup</i> pop
1229	sample	EUA	JAY-Z, Ye, Drake, Marvin Gaye $\Rightarrow$ sampling de rap moderno
1137	mashup	Japão/EUA	PSY, Daniel Ingram, Gorillaz, Quad City DJ's $\Rightarrow$ <i>mashup</i> de meme/internet
732	dj_mix	EUA	Skrillex, deadmau5, RL Grime, Knife Party $\Rightarrow$ EDM/dubstep
688	sample	EUA/França	Daft Punk, Justice, Porter Robinson $\Rightarrow$ <i>French touch</i> /eletrônico
576	remix	Japão	Den'onbu, Team Shanghai Alice, IOSYS $\Rightarrow$ Touhou/ <i>doujin</i>
412	sample	EUA/Austr.	100 geecs, Charli xcx, SOPHIE $\Rightarrow$ hyperpop
401	remix	Japão	Toby Fox, Koji Kondo, Nobuo Uematsu $\Rightarrow$ música de videogame

Tabela 3: Comunidades de artistas representativas (entre as maiores, via Louvain) e a cena correspondente. O tipo de relação dominante distingue cenas de *sampling* (hip-hop, rap) das de *mashup* (pop, rock) e *remix* (Touhou, videogame).

Tipo	Nós	Arestas	WCC gigante	in-degree médio	Maior cadeia
sample	30.691	22.706	22,6%	0,74	4
remix	206.741	128.560	0,2%	0,62	9
edit	57.386	31.728	0,1%	0,55	3
dj_mix	27.692	21.222	5,1%	0,77	2
mashup	18.561	18.668	60,5%	1,01	2

Tabela 4: Subgrafos por tipo de relação. *Sample* = derivação profunda e fragmentada; *mashup* = uma teia gigante e rasa; *remix/edit* = estrelas locais.

contemporâneo. A maior linhagem de derivação tem **9 saltos** (a série *Exquisite Corpse* de Simon Fisher Turner). As fontes *evergreen* (com derivadas em ≥ 5 décadas) incluem Donna Summer — *I Feel Love* (6 décadas), Lyn Collins — *Think (About It)* (in-degree 91) e The Winstons — *Amen, Brother* (53) — os *breaks* fundacionais que atravessam gerações. As Figuras 4a e 4b ilustram a distribuição de *lag* e o mapa de calor de fluxo entre décadas.

4.5 Fluxo geográfico

A *razão* de homofilia de país é **5,95** $\times$ o esperado pelo modelo nulo (89,9% das arestas são intra-país vs. 15,1% esperado). Os EUA são o grande exportador líquido de material (+3.983), seguidos por Japão (+638) e Jamaica (+233); os maiores importadores líquidos são Canadá (−1.378), Austrália (−1.148) e França (−762). Os principais corredores transfronteiriços confirmam a centralidade anglófona: RU $\rightarrow$ EUA (2.217), Canadá $\rightarrow$ EUA (1.298) e EUA $\rightarrow$ RU (1.297). A Figura 5 traz o mapa de calor país $\times$ país.

4.6 Camada de gênero

A homofilia de gênero é ainda mais forte — **8,13** $\times$ o nulo. O mais importante é que o balanço líquido **reproduz a história do sampling**: os maiores exportadores líquidos são *pop* (+5.356) e *rock* (+2.054), mas o padrão revelador são os gêneros-raiz *funk* (+1.511), *soul* (+1.318), *jazz* (+1.318) e *disco* (+806)




Figura 2: Distribuição de grau (*in/out*, escala simétrica-log) do grafo nível-faixa. Cauda pesada melhor descrita por lognormal que por lei de potência.





Figura 3: Tamanho de cada k -shell no grafo de artistas (escala log): a massa em $k \leq 1$ e o núcleo minúsculo em $k = 14$ caracterizam a estrutura core/periferia.

— também exportadores líquidos —, enquanto os maiores importadores são *electronic* (-3.153), *hip hop* (-2.614) e *dubstep* (-1.211). O corredor **hip hop**→**funk/soul** (840 e 748) recupera, sem supervisão, o fato canônico de que o hip-hop se construiu sobre *breaks* de funk e soul. A Figura 6 mostra a matriz de fluxo entre gêneros.


5 Estudo de Caso: Brasil

5.1 O Brasil no *backbone* CC0

O pilar geográfico trata o Brasil como um único nó; aqui descemos a **faixa e artista**. Das 1.430 gravações de artistas brasileiros, há 939 arestas em que o Brasil sampleia (173 transfronteiriças) e 957 em que é sampleado (191 transfronteiriças), das quais **766 são internas BR↔BR**. A rede interna é **muito fragmentada** (maior componente com apenas 18 faixas), e dominada por *remix* (598 de 766 arestas internas) — sinal de uma cena de EDM/funk contemporânea mais que de sampling histórico. O que o Brasil mais sampleia é o **cânone funk dos EUA**: Lyn Collins — *Think (About It)* (8×), James Brown e The Honey Drippers — *Impeach the President*.



(a) Distribuição do *lag* temporal (anos).



(b) Fluxo de derivação entre décadas.

Figura 4: Pilar temporal: o grosso das arestas é de curto *lag* (remix), com uma cauda longa de sampling de material antigo.

O dado mais interessante do *backbone* aberto é a **reutilização internacional de fontes brasileiras** — escassa (191 arestas) mas de alto perfil (Tabela 5): o MusicBrainz captura justamente os *samples* mundialmente célebres do acervo jazz/funk brasileiro.

Fonte brasileira	Reutilizada por	País
Eumir Deodato — <i>Skatin'</i> (1980)	The Notorious B.I.G. — <i>Nasty Girl</i>	EUA
Antônio Carlos Jobim — <i>Insensatez</i> (1963)	Black Eyed Peas — <i>Sexy</i>	EUA
Luiz Bonfá — <i>Seville</i> (1968)	Gotye — <i>Somebody That I Used to Know</i>	Austrália
Arthur Verocai — <i>Seriado</i> (1972)	MF DOOM (Metal Fingers) — <i>Passion Flower</i>	EUA
Nana Caymmi — <i>Tens (Calmaria)</i> (1975)	Nujabes — <i>Luv (sic.) Pt 3</i>	Japão

Tabela 5: Reutilização internacional de fontes brasileiras detectada no MusicBrainz (CC0). O dado aberto enxerga sobretudo o que é célebre na esfera anglófona.

5.2 O que os dados abertos não veem: comparação com o Genius

Para medir a **lacuna de disponibilidade de dados** para o Brasil, consultou-se a API pública do Genius para as mesmas 1.430 faixas (*src/exploration/*). O Genius expõe relações que o MusicBrainz não modela — em especial **interpolações**. Dos 1.430 registros, 1.135 (79,4%) tiveram correspondência e 709 foram verificados, produzindo **1.459 arestas de derivação verificadas** (contra ~1.130 do MusicBrainz tocando o Brasil), das quais **193 interpolações** — categoria inexistente no *backbone* aberto. A Tabela 6 contrasta as duas fontes.

	MusicBrainz (CC0, no repositório)	Genius (proprietário, só citado)
Cobertura	1.430 faixas BR (100%)	1.135 correspondidas; 709 verificadas
Arestas tocando o BR	~1.130	1.459 verificadas
Interpolações	nenhuma (tipo inexistente)	193
Sabor	acervo jazz/funk histórico	cena moderna + acervo

Tabela 6: MusicBrainz vs. Genius para o Brasil. O Genius praticamente dobra a contagem de arestas e adiciona interpolações e a cena contemporânea.




Figura 5: Fluxo de derivação país→país (log, top-20). Linha = país derivado; coluna = país-fonte.

Contando apenas *sample*+*interpolação* (excluindo remixes/covers), as fontes brasileiras mais reutilizadas segundo o Genius são **Barbatuques** — *Baianá* (60, hoje um marco do *drum and bass* global via Nia Archives), **MC Fioti** — *Bum Bum Tam Tam* (36), **Tim Maia** — *Ela Partiu* (17), **Rodrigo Amarante** — *Tuyo* (15, tema de *Narcos*), Racionais MC's, Arthur Verocai e Sérgio Mendes. Já o que as faixas brasileiras mais *sampleiam/interpolam* revela um padrão curioso: **música clássica** (J.S. Bach — *Partita* BWV 1013, 10×; Paganini) e o cânone global do *breakbeat* (The Winstons — *Amen, Brother*; Sugarhill Gang — *Rapper's Delight*), ao lado das próprias raízes (Jobim, Os Mutantes).

Achado central do estudo de caso: o MusicBrainz mostra o Brasil como *fonte* líquida de jazz/funk para o hip-hop e a eletrônica globais, mas é **esparso demais para enxergar a cena doméstica**; a riqueza do *sampling* brasileiro vive em bases proprietárias (Genius/WhoSampled), não em dados abertos — uma constatação de disponibilidade de dados, em si, relevante. Por isso o Genius é usado apenas como **estudo de caso citado**: as arestas brutas não são redistribuídas no repositório (permanecem em *private*/, fora do versionamento), e o *backbone* CC0 do MusicBrainz é a base reproduzível.

6 Discussão e Conclusões

Os algoritmos de grafo, aplicados às instâncias do MusicBrainz, recuperam padrões musicais reais **sem qualquer rótulo semântico como entrada**: a detecção de comunidades isola cenas coerentes (hip-hop de *breaks*, French touch, Touhou, videogame, hyperpop); o fluxo de gênero reconstrói a relação fundacional hip-hop→funk/soul; o pilar temporal distingue *sample* (reativa material com 14 anos de *lag* mediano) de *remix* (contemporâneo); e a análise de papéis separa fontes, sampleadores curatoriais, autoridades pop e pontes. Estruturalmente, mostramos que a rede **não é “livre de escala”** no sentido estrito (lognormal vence a lei de potência) e que cada tipo de relação tem assinatura topológica própria. O estudo de caso do Brasil ilustra, de forma concreta, tanto o que os dados abertos capturam (reutilização internacional célebre) quanto o que lhes escapa (a cena doméstica), quantificando a lacuna frente a uma fonte proprietária.

Limitações. A cobertura do MusicBrainz é colaborativa e anglófona-enviesada (75% dos nós têm país; *sample* é só ~10% das arestas, dominadas por *remix*); o estudo do Brasil é, portanto, limitado pela esparsidade




Figura 6: Fluxo de derivação gênero→gênero. O bloco hip hop/electronic → funk/soul/jazz é o padrão dominante.

do dado aberto.

A Reprodutibilidade, ética de dados e uso de IA

Reprodutibilidade. Todo o pipeline CC0 é reexecutável a partir do dump público; as instâncias e os artefatos de análise estão versionados no repositório. **Ética de dados.** Os dados do Genius são proprietários (uso não comercial; a parte protegida são as letras, que não tocamos): apenas estatísticas agregadas e exemplos ilustrativos são citados, sem redistribuição das arestas brutas. **Uso de IA.** Em conformidade com a regra do curso, declara-se o uso do assistente Claude (Anthropic) como apoio à implementação do pipeline de análise e à redação deste relatório; a responsabilidade pelo conteúdo, verificação dos resultados e condução do trabalho é integralmente do autor.